

ollama_ros_chat 功能包使用文档

1. 功能简介

ollama_ros_chat 是一款基于 ROS2 开发的功能包，旨在为机器人系统提供高效的人机对话交互能力。该功能包集成 Ollama 平台和 DeepSeek-R1 模型，通过 ROS2 的消息传递机制，接收用户的输入并将其发送到 DeepSeek-R1 模型进行处理，然后将模型的响应反馈给用户，实现自然、高效的人机对话，DeepSeek-R1 模型在本地运行，确保用户数据不被上传到云端，充分保护用户隐私。

2. ROS2 使用方法


① 服务通信使用示例

在进行 SSH 远程登录后的终端运行 ollama_ros_chat 对应的启动文件

（SSH 远程登录操作请查看 ROS2 小车上手操作文档或功能演示视频）

分别打开两个终端启动服务端与客户端

```
ros2 run ollama_ros_chat chat_service
```



```
wheeltec@wheeltec: ~  
wheeltec@wheeltec: ~ 80x20  
wheeltec@wheeltec:~$ ros2 run ollama_ros_chat chat_service  
[INFO] [1742288233.875123970] [ollama_server]: Available models: deepseek-r1:7b-qwen-distill-q4_K_M  
[INFO] [1742288233.875921118] [ollama_server]: Selected model: deepseek-r1:7b-qwen-distill-q4_K_M  
[INFO] [1742288233.918523315] [ollama_server]: Ollama Chat Server Node initialized  
Received message: 你是谁？你能做什么？  
Response_content: <think>  
我是DeepSeek-R1，一个由深度求索公司开发的智能助手，我会尽我所能为您提供帮助。  
</think>  
我是DeepSeek-R1，一个由深度求索公司开发的智能助手，我会尽我所能为您提供帮助。  
Time taken: 8.810605525970459
```

图 2.1 终端运行命令行示意图

终端输出可用模型以及当前选择模型，接收到服务请求时输出问题以及推理内容。

```
ros2 run ollama_ros_chat chat_client
```

```
wheeltec@wheeltec: ~  
wheeltec@wheeltec: ~ 80x20  
wheeltec@wheeltec:~$ ros2 run ollama_ros_chat chat_client  
[INFO] [1742288236.590919860] [ollama_client]: Chat Client Node initialized  
Chat Client Node is running  
  
user: 你是谁? 你能做什么?  
<think>  
我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 我会尽我所能为您提供帮助。  
</think>  
  
我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 我会尽我所能为您提供帮助。  
response done.  
  
user: 
```

图 2.2 终端运行命令行示意图

用户可以在终端输入问题或者其他内容, 等待模型推理完成可以看到输出内容。

② 话题通信使用示例

在进行 SSH 远程登录后的终端运行 `ollama_ros_chat` 对应的启动文件
(SSH 远程登录操作请查看 ROS2 小车上手操作文档或功能演示视频)
分别打开两个终端启动话题通信的服务端与客户端

```
ros2 run ollama_ros_chat topic_server
```


```
wheeltec@wheeltec: ~  
wheeltec@wheeltec: ~ 80x20  
wheeltec@wheeltec:~$ ros2 run ollama_ros_chat topic_server  
[INFO] [1742289683.908777464] [ollama_topic_server]: Available models: deepseek-r1:7b-qwen-distill-q4_K_M  
[INFO] [1742289683.909480588] [ollama_topic_server]: Selected model: deepseek-r1:7b-qwen-distill-q4_K_M  
[INFO] [1742289691.396671317] [ollama_topic_server]: Ollama Chat Server Node initialized  
Received message: 你是谁? 你能做什么?  
Response_content: <think>  
  
</think>  
  
您好! 我是由中国的深度求索 (DeepSeek) 公司开发的智能助手DeepSeek-R1。有关模型和产品的详细内容请参考官方文档。  
Time taken: 24.122215509414673  

```

图 2.3 终端运行命令行示意图

终端输出可用模型以及当前选择模型，接收到服务请求时输出问题以及推理内容。

```
ros2 run ollama_ros_chat topic_client
```




```
wheeltec@wheeltec: ~  
wheeltec@wheeltec: ~ 80x20  
wheeltec@wheeltec:~$ ros2 run ollama_ros_chat topic_client  
[INFO] [1742289687.384415394] [ollama_topic_client]: Chat Client Node initialized  
Chat Client Node is running  
  
user: 你是谁？你能做什么？  
<think>  
  
</think>  
  
您好！我是由中国的深度求索（DeepSeek）公司开发的智能助手DeepSeek-R1。有关模型和产品的详细内容请参考官方文档。  
user: 
```

图 2.4 终端运行命令行示意图

用户可以在终端输入问题或者其他内容，等待模型推理完成可以看到输出内容。

③ 在线大模型切换使用说明



```
ollama_params.yaml  
ollama_ros_chat > config > ollama_params.yaml > {} ollama_topic_server > {} ros_parameters  
1 # Ollama/OpenAI 兼容接口参数  
2 chat_service:  
3   ros_parameters:  
4     #base_url: "http://localhost:11434/v1" # 本地 Ollama  
5     #api_key: "ollama" # 本地随意写，阿里云填真实 key  
6     base_url: "https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云示  
7     api_key: "sk-*****"  
8     use_model: "deepseek-r1"  
9     # use_model: "" # 空 = 自动选第一个；也可写成 "de  
10    stream: false # true = 流式  
11    temperature: 0.5  
12    history_length: 10  
13
```

图 2.5 大模型切换在线参数说明示例

```
ollama_ros_chat > config > ollama_params.yaml > ...
1 # Ollama/OpenAI 兼容接口参数
2 chat_service:
3   ros_parameters:
4     base_url: "http://localhost:11434/v1" # 本地 Ollama
5     api_key: "ollama" # 本地随意写; 阿里云填真实 key
6     # base_url: "https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云
7     # api_key: "sk-*****"
8     use_model: "deepseek-r1"
9     # use_model: "" # 空 = 自动选第一个; 也可写成 "de
10    stream: false # true = 流式
11    temperature: 0.5
12    history_length: 10
```

图 2.6 大模型切换离线参数说明示例

注意：调用参数文件需要使用 launch 文件启动，如果使用 node 节点启动需要在 python 程序中修改默认参数。

在线大模型可以通过申请通义千问 API_KEY 进行使用，需要修改对应的 base_url、api_key、use_model 相关参数，使用离线模型需要切换到本地对应的参数

```
#本地模型使用
base_url: "http://localhost:11434/v1" # 本地 Ollama
api_key: "ollama" # 本地随意写; 阿里云填真实 key
use_model: "" # 空 = 自动选第一个; 也可写成
"deepseek-r1"

#在线模型使用
base_url: "https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云示例
api_key: "sk-*****"
use_model: "deepseek-r1"

#launch 文件启动方式
ros2 launch ollama_ros_chat ollama_ros_chat.launch.py
```

3. ROS1 使用方法

① 服务通信使用示例

在进行 SSH 远程登录后的终端运行 ollama_chat_ros 对应的启动文件
 （SSH 远程登录操作请查看 ROS1 小车上手操作文档或功能演示视频）
 分别打开三个终端启动 roscore、服务端与客户端

```
roscore
roslaunch ollama_chat_ros chat_service.py
```



```
wheeltec@wheeltec: ~  
wheeltec@wheeltec:~$ rosrund ollama_chat_ros chat_service.py  
[INFO] [1936.801666]: Available models: deepseek-r1:1.5b-qwen-distill-q4_K_M  
[INFO] [1936.805013]: Selected model: deepseek-r1:1.5b-qwen-distill-q4_K_M  
[INFO] [1941.421837]: Ollama Chat Server Node initialized  
[INFO] [2000.224201]: Received message: 你是谁? 你能做什么?  
<think>  
您好! 我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 有关模型和所有相关知识  
Please refer to the official documentation. 如果有任何问题, 欢迎随时提问。  
</think>  
您好! 我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 有关模型和所有相关知识  
Please refer to the official documentation. 如果有任何问题, 欢迎随时提问。[INFO]  
[2014.803783]: Response_content: <think>  
您好! 我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 有关模型和所有相关知识  
Please refer to the official documentation. 如果有任何问题, 欢迎随时提问。  
</think>  
您好! 我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 有关模型和所有相关知识  
Please refer to the official documentation. 如果有任何问题, 欢迎随时提问。  
Time taken: 14.565047423999886
```

图 3.1 终端运行命令行示意图

终端输出可用模型以及当前选择模型, 接收到服务请求时输出问题以及推理内容。

```
rosrund ollama_chat_ros chat_client.py
```

```
wheeltec@wheeltec: ~  
wheeltec@wheeltec:~$ rosrund ollama_chat_ros chat_client.py  
[INFO] [1983.914057]: Chat Client Node initialized  
Chat Client Node is running  
user: 你是谁? 你能做什么?  
[INFO] [2000.217249]: Received message: 你是谁? 你能做什么?  
<think>  
您好! 我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 有关模型和所有相关知识  
Please refer to the official documentation. 如果有任何问题, 欢迎随时提问。  
</think>  
您好! 我是DeepSeek-R1, 一个由深度求索公司开发的智能助手, 有关模型和所有相关知识  
Please refer to the official documentation. 如果有任何问题, 欢迎随时提问。  
response done.  
user: □
```

图 3.2 终端运行命令行示意图

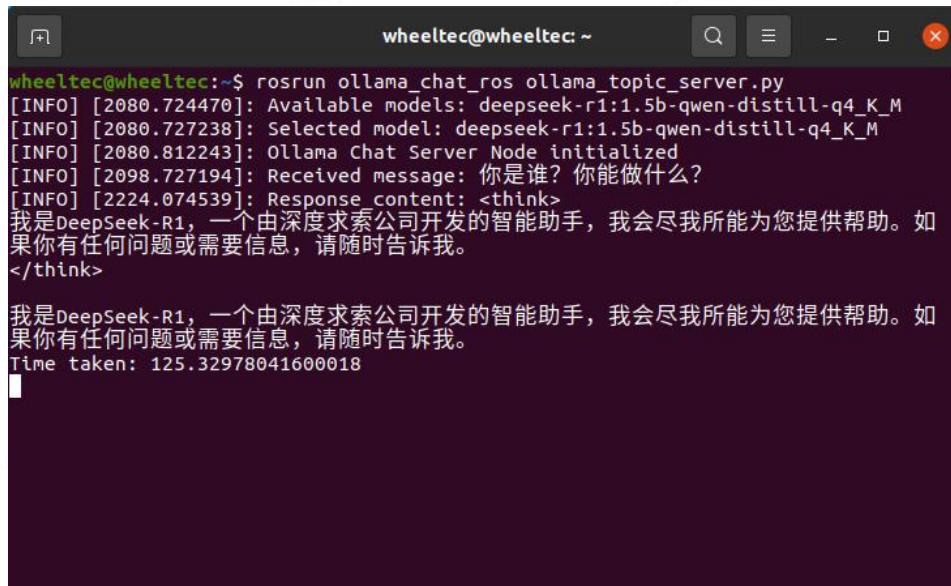
用户可以在终端输入问题或者其他内容, 等待模型推理完成可以看到输出内容。

② 话题通信使用示例

在进行 SSH 远程登录后的终端运行 ollama_chat_ros 对应的启动文件 (SSH 远程登录操作请查看 ROS1 小车上手操作文档或功能演示视频)

分别打开三个终端启动 roscore、话题通信的服务端与客户端

```
roscore  
roslaunch ollama_chat_ros ollama_topic_server.py
```

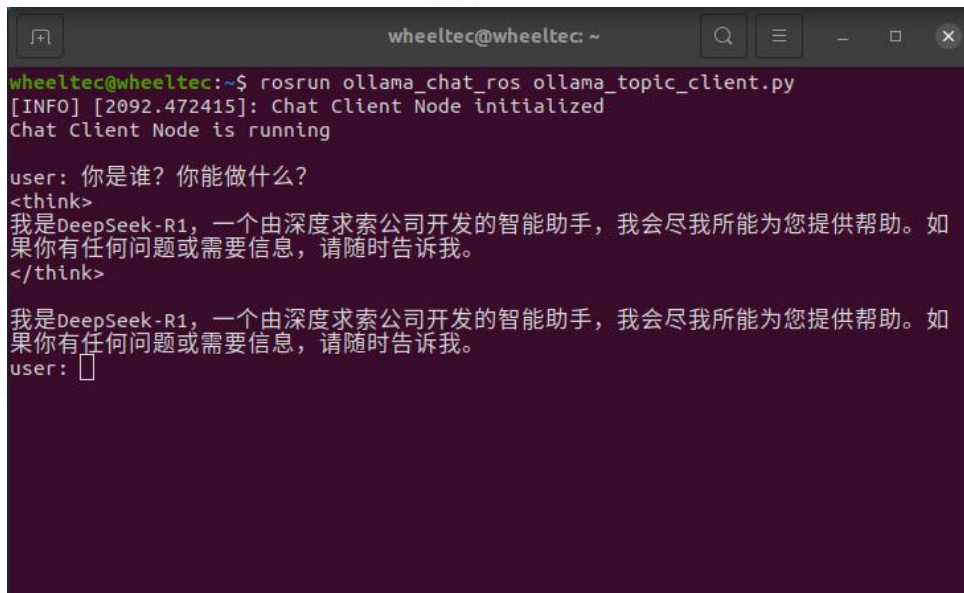


```
wheeltec@wheeltec: ~  
wheeltec@wheeltec:~$ roslaunch ollama_chat_ros ollama_topic_server.py  
[INFO] [2080.724470]: Available models: deepseek-r1:1.5b-qwen-distill-q4_K_M  
[INFO] [2080.727238]: Selected model: deepseek-r1:1.5b-qwen-distill-q4_K_M  
[INFO] [2080.812243]: Ollama Chat Server Node initialized  
[INFO] [2098.727194]: Received message: 你是谁？你能做什么？  
[INFO] [2224.074539]: Response content: <think>  
我是DeepSeek-R1，一个由深度求索公司开发的智能助手，我会尽我所能为您提供帮助。如果你有任何问题或需要信息，请随时告诉我。  
</think>  
  
我是DeepSeek-R1，一个由深度求索公司开发的智能助手，我会尽我所能为您提供帮助。如果你有任何问题或需要信息，请随时告诉我。  
Time taken: 125.32978041600018
```

图 3.3 终端运行命令行示意图

终端输出可用模型以及当前选择模型，接收到服务请求时输出问题以及推理内容。

```
roslaunch ollama_chat_ros ollama_topic_client.py
```



```
wheeltec@wheeltec: ~  
wheeltec@wheeltec:~$ roslaunch ollama_chat_ros ollama_topic_client.py  
[INFO] [2092.472415]: Chat Client Node initialized  
Chat Client Node is running  
  
user: 你是谁？你能做什么？  
<think>  
我是DeepSeek-R1，一个由深度求索公司开发的智能助手，我会尽我所能为您提供帮助。如果你有任何问题或需要信息，请随时告诉我。  
</think>  
  
我是DeepSeek-R1，一个由深度求索公司开发的智能助手，我会尽我所能为您提供帮助。如果你有任何问题或需要信息，请随时告诉我。  
user: 
```

图 3.4 终端运行命令行示意图

用户可以在终端输入问题或者其他内容，等待模型推理完成可以看到输出内容。

③ 在线大模型切换使用说明

```
ollama_params.yaml x
config > ollama_params.yaml > # history_length
1 #base_url: "http://localhost:11434/v1" # 本地 Ollama
2 #api_key: "ollama" # 本地随意写; 阿里云填真实 key
3 base_url: "https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云示例
4 api_key: "sk-*****"
5 use_model: "deepseek-r1"
6 # use_model: "" # 空 = 自动选第一个; 也可写成 "deepseek-r1"
7 stream: false # true = 流式
8 temperature: 0.5
9 history_length: 10
```

图 3.5 大模型切换在线版参数说明示例

```
ollama_params.yaml x chat_service.py
config > ollama_params.yaml > # history_length
1 base_url: "http://localhost:11434/v1" # 本地 Ollama
2 api_key: "ollama" # 本地随意写; 阿里云填真实 key
3 # use_model: "" # 空 = 自动选第一个; 也可写成 "deepse
4 # base_url: "https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云示例
5 # api_key: "sk-*****"
6 use_model: "deepseek-r1"
7 stream: false # true = 流式
8 temperature: 0.5
9 history_length: 10
```

图 3.6 大模型切换离线参数说明示例

注意：调用参数文件需要使用 launch 文件启动，如果使用 node 节点启动需要在 python 程序中修改默认参数。

在线大模型可以通过申请通义千问 API_KEY 进行使用，需要修改对应的 base_url、api_key、use_model 相关参数，使用离线模型需要切换到本地对应的参数

```
#本地模型使用
base_url: "http://localhost:11434/v1" # 本地 Ollama
api_key: "ollama" # 本地随意写; 阿里云填真实 key
use_model: "" # 空 = 自动选第一个; 也可写成
"deepseek-r1"

#在线模型使用
base_url: "https://dashscope.aliyuncs.com/compatible-mode/v1" # 阿里云示例
api_key: "sk-*****"
use_model: "deepseek-r1"

#launch 文件启动方式
```



```
roslaunch ollama_chat_ros ollama_chat_ros.launch
```

4. 注意事项


1. ollama_ros_chat 功能基于 ollama 平台以及 deepseek-r1 模型，需要客户提前安装 ollama 并且拉取模型才可以正常运行。

2. 直接编译运行有可能报错缺少 requests 模块需要使用 pip 进行安装

```
pip3 install requests
```

3. 服务通信更适合硬件性能不高的主控

4. 对于服务通信可以在服务端设置一定的请求时间，超过时间会显示 Read time out，可以在程序中修改等待时间。



```
wheeltec@wheeltec: ~  
wheeltec@wheeltec: ~ 80x24  
wheeltec@wheeltec:~$ ros2 run ollama_ros_chat chat_service  
[INFO] [1742287995.270616827] [ollama_server]: Available models: deepseek-r1:7b-qwen-distill-q4_K_M  
[INFO] [1742287995.271365751] [ollama_server]: Selected model: deepseek-r1:7b-qwen-distill-q4_K_M  
[INFO] [1742288003.044613418] [ollama_server]: Ollama Chat Server Node initialized  
Received message: 你是谁? 你能做什么?  
[ERROR] [1742288029.579806622] [ollama_server]: An error occurred: HTTPConnectionPool(host='localhost', port=11434): Read timed out. (read timeout=5)  
Response_content: None  
Time taken: 5.007258653640747  
█
```

图 4.1 服务通信响应超时报错


```

ollama_service.py
ollama_ros_chat > ollama_ros_chat > ollama_service.py ...
11 class OllamaChatNode(Node):
102     """Get response from Ollama model"""
103     def get_response(self, messages: List[Dict[str, str]]) -> Optional[str]:
104         try:
105             prompt = self._convert_messages_to_prompt(messages)
106             url = f"{self.base_url}/api/generate"
107             data = {
108                 "model": self.use_model,
109                 "prompt": prompt,
110                 "stream": self.stream,
111                 "temperature": self.temperature
112             }
113
114             response = requests.post(url, json=data, stream=self.stream, timeout=120)
115             if response.status_code == 200:
116                 full_response = ""
117                 for line in response.iter_lines():
118                     if line:
119                         json_response = json.loads(line)
120                         if 'response' in json_response:
121                             chunk = json_response['response']
122                             full_response += chunk
123                             #print(chunk, end='', flush=True)
124                             if json_response['done'] is True:
125                                 return full_response
126             else:
127                 self.get_logger().error(f"Error: Received status code {response.status_code}")
128                 return None
129
130         except Exception as e:
131             self.get_logger().error(f"An error occurred: {e}")
132             return None

```

图 4.2 服务通信服务端响应时间限制代码

5. 功能讲解及参数说明

ollama_ros_chat 功能示例涉及源码主要为 Python 文件，启动节点分别为服务端和客户端节点，如果有需要可以分别将服务端或者客户端集成在自己的程序当中。

在 ROS2 的功能包中 Python 文件与功能节点的对应关系可以在 setup.py 文件中看到：

```

'console_scripts': [
    'topic_server = ollama_ros_chat.ollama_topic_server:main',
    'topic_client = ollama_ros_chat.ollama_topic_client:main',
    'chat_service = ollama_ros_chat.ollama_service:main',
    'chat_client = ollama_ros_chat.ollama_client:main',
]

```

ROS2 通信方式及其接口：

通信类型	话题通信	服务通信
客户端输入请求	/chat_message	/chat_service
服务端返回内容	/chat_response	/chat_service

服务端相关参数说明：

参数名	类型	参数说明
base_url	String	表示 Ollama 服务的地址
use_model	String	用于指定当前正在使用的模型，初始值为 None，表示尚未选择具体的模型。
stream	Bool	控制是否以流式（streaming）的方式接收响应
temperature	Float	表示模型生成响应时的温度（temperature）参数，取值范围通常在 0 到 1 之间。它用于控制模型生成响应的随机性或多样性。
history_length	Int	定义了对话历史中保留的消息数量